



GEDİK MESLEK YÜKSEKOKULU
BİLGİSAYAR TEKNOLOJİLERİ BÖLÜMÜ
BİLGİSAYAR PROGRAMCILIĞI PROGRAMI

DERİN ÖĞRENME (CPP214)

FİNAL ÖDEVİ

KONU:

Derin Öğrenme Tabanlı CNN Mimarisi ile Meyve Sınıflandırması

Elçin Tok

241110001

Kübra Demirtaş

241110004

1. GİRİŞ

Günümüzde teknolojinin hızla ilerlemesiyle birlikte, bilgisayarlı görü (Computer Vision) ve derin öğrenme (Deep Learning) teknikleri birçok endüstride kritik bir rol oynamaya başlamıştır. Özellikle gıda ve tarım sektörü, üretim süreçlerinin otomasyonu, kalite kontrol süreçlerinin hızlandırılması ve insan hatasının minimize edilmesi amacıyla bu teknolojilere yoğun ilgi göstermektedir. Geleneksel yöntemlerle meyvelerin sınıflandırılması; iş gücü yoğunluğu, yavaşlık ve kişisel değerlendirmelere dayalı hata payı gibi dezavantajlar barındırmaktadır.

Bu çalışmanın temel konusu, Evrişimli Sinir Ağları (Convolutional Neural Networks - CNN) mimarisi kullanılarak elma, armut ve şeftali gibi meyve türlerinin dijital görseller üzerinden otomatik olarak sınıflandırılmasıdır. Geçmişte bu alanda yapılan çalışmalar incelendiğinde, ilk dönemlerde renk histogramları ve kenar belirleme gibi manuel özellik çıkarımı (feature extraction) yöntemlerinin kullanıldığı görülmektedir. Ancak 2012 yılında AlexNet'in başarısıyla ivme kazanan derin öğrenme yaklaşımları, özellik çıkarımını otomatik hale getirerek sınıflandırma doğruluğunu %90'ların üzerine taşımıştır.

Bu proje kapsamında oluşturulan model, derin öğrenme algoritmalarının görsel veri üzerindeki güçlü temsil yeteneğinden yararlanmaktadır. Çalışmanın amacı, farklı ışık, açı ve arka plan koşullarında bile meyveleri yüksek doğruluk oranıyla ayırt edebilen bir sistem geliştirmektir. Bu tür sistemler, gelecekte akıllı tarım uygulamalarında, marketlerdeki otomatik kasa sistemlerinde ve endüstriyel paketleme tesislerinde verimliliği artırmak adına büyük bir potansiyel taşımaktadır.

2. MATERYAL

Bu çalışmada kullanılan veri seti, modelin gerçek dünya koşullarında yüksek başarı göstermesi ve genelleme yeteneğinin artırılması amacıyla hibrit bir yapıda oluşturulmuştur. Veri seti hazırlık süreci iki temel aşamadan oluşmaktadır:

2.1. Sınıf Seçim Kriterleri

Proje kapsamında elma, armut ve şeftali meyvelerinin seçilmesinin arkasında hem teknik hem de pratik nedenler bulunmaktadır:

2.1.1. Morfolojik Benzerlik ve Ayırt Edici Özellikler

Elma, armut ve şeftali; genel form (yuvarlaklık), boyut ve bazen renk açısından birbirine oldukça benzer meyvelerdir. Özellikle bazı elma ve şeftali türleri renk bazında; bazı armut ve elma türleri ise şekil bazında birbirine yakınlık gösterir. Bu benzerlik, derin öğrenme modelinin sadece "renk" gibi basit bir özelliğe odaklanmamasını, meyvenin dokusu (şeftalinin tüylü yapısı), sap yapısı ve spesifik form detaylarını (armudun boyun yapısı) öğrenmesini zorunlu kılar. Bu da modelin özellik çıkarımı (feature extraction) yeteneğini maksimize eder.

2.1.2. Endüstriyel Karşılık ve Uygulanabilirlik

Türkiye, dünya çapında elma, armut ve şeftali üretiminde lider ülkelerden biridir. Bu üç meyve, endüstriyel boy boylama (sizing) ve otomatik paketleme tesislerinde en çok işlem gören ürün

gruplarıdır. Bu meyvelerin otomatik olarak hatasız sınıflandırılması, tarım teknolojileri ve akıllı paketleme sistemleri için doğrudan bir ticari karşılığa sahiptir.

2.1.3. Veri Çeşitliliği Stratejisi (Ağaç Üstü Görseller)

Özellikle bu meyvelerin ağaç üzerindeki hallerinin seçilme nedeni, modelin doğadaki karmaşayla başa çıkabilmesini sağlamaktır.

Elma: Genelde yapraklar arasında kümelenmiş halde bulunur.

Armut: Formu nedeniyle daldaki duruş açısı çok değişkendir.

Şeftali: Arka planla (yapraklarla) benzer renk tonlarına sahip olabilir.

Bu zorluklar modelin karmaşık arka planlar altında ayırt edici özellikleri öğrenmesini sağlamaktadır.

2.2. Veri Kaynakları ve Çeşitlilik

Projenin temelini oluşturmak adına başlangıçta literatürde yaygın olarak kullanılan hazır veri setlerinden yararlanılmıştır. Ancak modelin sadece izole edilmiş, laboratuvar ortamındaki görselleri değil; karmaşık arka planlara sahip gerçek doğa görsellerini de tanıması hedeflenmiştir. Bu doğrultuda, elma, armut ve şeftali sınıfları için doğrudan ağaç üzerinde, farklı ışık açıları ve gölge koşullarında çekilmiş özgün görseller veri setine dahil edilmiştir.

2.2.1 Hazır Veri Seti Kaynağı ve Metodolojisi

Çalışmanın temelini oluşturan hazır veriler, literatürde bilgisayarlı görü projelerinde standart kabul edilen "Fruits-360" veri setinden (Kaggle üzerinden) temin edilmiştir. Bu veri setinin oluşturulma metodolojisi incelendiğinde, yüksek hassasiyetli bir veri toplama süreci izlendiği görülmektedir. Kaynak veri setinin oluşturulma aşamaları şu şekildedir:

Kontrollü Ortam Çekimleri: Meyveler, düşük hızda dönen bir motor düzeneğine yerleştirilmiş ve sabit bir kamera karşısında 360 derecelik bir açıyla kaydedilmiştir. Bu sayede her meyvenin her yönden görünümü veri setine dahil edilmiştir.

Arka Plan Temizleme: Hazır veri setindeki resimler, modelin meyve formuna odaklanmasını kolaylaştırmak amacıyla beyaz bir arka plan (255, 255, 255) üzerinde dijitalleştirilmiştir.

Teknik Özellikler: Resimler başlangıçta yüksek çözünürlüklü olarak çekilmiş, ancak işlem maliyetini optimize etmek adına 100x100 piksel boyutuna indirgenmiştir.


2.2.3 Hibrit Yaklaşımın Gerekliliği

Hazır veri setinin sunduğu bu "ideal ve steril" ortam, modelin meyvelerin temel geometrik yapılarını öğrenmesi için mükemmel bir başlangıç noktası sağlamıştır. Ancak, projenin özgün kısmını oluşturan kendi topladığımız ağaç üstü görseller, bu ideal öğrenmeyi gerçek hayatın karmaşasıyla birleştirmiştir. Hazır veri setinden gelen 360 derecelik ürün bilgisi ile bizim eklediğimiz doğal ortam (yaprak, gölge, dal) bilgisi harmanlanarak, modelin hem ürün detaylarını hem de çevresel gürültüyü ayırt edebilecek seviyeye gelmesi sağlanmıştır.

Bilerek ve isteyerek ağaç üzerindeki meyve görsellerinin seçilmesinin iki temel nedeni bulunmaktadır:

- 1) Veri Çeşitliliği (Data Diversity): Modelin meyveyi sadece pürüzsüz bir zeminde değil, yapraklar, dallar ve diğer çevresel faktörlerle birlikte tanımasını sağlayarak dayanıklılığını (robustness) artırmak.
- 2) Sınıflandırma Zorluğu (Classification Challenge): Modelin özellik çıkarımı (feature extraction) kapasitesini zorlayarak, benzer renk ve dokuya sahip nesneleri (örneğin yeşil yapraklar arasındaki yeşil bir elma) ayırt etme becerisini geliştirmek.

Bu yöntemle toplamda 3517 adet görselden oluşan dengeli ve zorlayıcı bir veri seti elde edilmiştir. Eğitim sürecinde veriler %70 eğitim, %15 doğrulama ve %15 test seti olarak ayrılmıştır.



Şekil 1. Önerilen çalışmanın akış şeması.

3. YÖNTEM

Bu bölümde, meyve sınıflandırma işleminin gerçekleştirilmesi için tasarlanan derin öğrenme modelinin mimarisi, kullanılan algoritmalar, eğitim stratejileri ve teknik altyapı detaylandırılmıştır.

3.1. Algoritma Seçimi ve Mimari Yapı

Projede, görsel veri işleme konusundaki başarısı kanıtlanmış olan **Evrişimli Sinir Ağları (Convolutional Neural Networks - CNN)** algoritması tercih edilmiştir. CNN, geleneksel makine öğrenmesi yöntemlerinden farklı olarak, görsel üzerindeki öznitelikleri (kenar, doku, form) manuel müdahaleye gerek duymadan hiyerarşik bir yapıda otomatik olarak çıkarabilmektedir.

Tasarlanan model mimarisi şu katmanlardan oluşmaktadır:

- Evrişimli Katmanlar (Convolutional Layers):** Model, 32, 64 ve 128 kanallı olmak üzere üç temel evrişim aşamasından oluşmaktadır. Bu aşamalar meyvelerin karmaşık doku detaylarını (şeftali tüyü, elma pürüzsüzlüğü vb.) öğrenmektedir.
- Aktivasyon Fonksiyonu:** Doğrusallığı ortadan kaldırmak ve modelin karmaşık kalıpları öğrenmesini sağlamak için ReLU (Rectified Linear Unit) fonksiyonu kullanılmıştır.
- Havuzlama Katmanları (Pooling):** MaxPooling (2x2) yöntemiyle özellik haritalarının boyutu küçültülerek hesaplama maliyeti düşürülmüş ve modelin nesne kaymalarına karşı direnci artırılmıştır.
- Tam Bağlantılı Katmanlar (Fully Connected/Dense):** Özellik çıkarımından sonra veriler düzleştirilerek (Flatten) 256 nöronluk gizli bir katmana ve ardından 3 sınıflı (elma, armut, şeftali) çıkış katmanına aktarılmıştır.

3.2. Model Parametreleri ve Hiperparametreler

Modelin eğitim performansını belirleyen teknik parametreler aşağıda Tablo 1'de sunulmuştur:

Tablo 1: Model Eğitim ve Hiperparametre Tablosu

Parametre Adı	Değeri / Seçimi	Açıklama
Giriş Boyutu	100x100x3 (RGB)	Görsellerin standart boyutu
Optimizer (Optimizasyon)	Adam	Hızlı yakınsama ve dinamik öğrenme hızı
Kayıp Fonksiyonu	Cross Entropy Loss	Çok sınıflı sınıflandırma için standart
Öğrenme Hızı (LR)	0.001	Ağırlık güncellenme hızı
Batch Size (Yığın)	32	Her adımda işlenen görsel sayısı

Epoch (Dönem)	50 (Maksimum)	Veri setinin toplam taranma sayısı
Dropout Oranı	0.5 (%50)	Ezberlemeyi (Overfitting) önleme
Ağırlık Azalımı (WD)	1e-4	L2 Regularization ile stabilizasyon

Tablo 1’de sunulan hiperparametreler, modelin eğitim sürecinde dengeli bir öğrenme performansı göstermesi amacıyla belirlenmiştir. Özellikle Dropout ve Weight Decay yöntemleri kullanılarak aşırı öğrenmenin (overfitting) azaltılması hedeflenmiştir.

3.3. Deneysel Süreç ve Optimizasyon

Çalışma son haline gelmeden önce modelin başarısını artırmak adına çeşitli denemeler yapılmıştır:

- Katman Derinliği Testleri:** Başlangıçta daha sığ (2 katmanlı) bir mimari denenmiş, ancak ağaç üzerindeki karmaşık görsellerde başarının yeterli seviyeye ulaşmaması üzerine model derinliği artırılarak üç evrişim katmanlı bir yapı tercih edilmiştir.
- Aşırı Öğrenme (Overfitting) Problemi:** İlk denemelerde eğitim doğruluğunun çok yüksek seviyelere ulaşmasına rağmen doğrulama performansının aynı oranda artmadığı gözlemlenmiştir. Bu sorunu azaltmak amacıyla mimariye %50 oranında Dropout katmanı eklenmiş ve modelin genelleme yeteneği artırılmıştır.
- Erken Durdurma (Early Stopping):** Modelin gereksiz yere eğitilmesini ve validasyon kaybının artmasını önlemek amacıyla, kaybın 5 epoch boyunca iyileşmediği durumlarda eğitimi sonlandıran bir mekanizma kurulmuştur.

3.4. Kullanılan Teknolojiler ve Kütüphaneler

Projenin geliştirme sürecinde Python programlama dili ve aşağıdaki kütüphaneler kullanılmıştır:

- PyTorch & Torchvision:** Model mimarisinin kurulması, katmanların yönetimi ve tensör işlemleri için kullanılmıştır.
- Scikit-Learn:** Verilerin bölünmesi (Split) ve performans metriklerinin (F1, Precision, Recall) hesaplanması için tercih edilmiştir.
- Matplotlib & Seaborn:** Eğitim sonuçlarının grafikleştirilmesi ve Confusion Matrix görselleştirmesi için kullanılmıştır.
- Google Colab (GPU/CUDA):** Eğitim süresini hızlandırmak amacıyla bulut tabanlı GPU donanımı kullanılmıştır.

4. SONUÇLAR

Bu bölümde, hibrit meyve veri seti üzerinde eğitilen CNN modelinin test seti üzerindeki performans sonuçları nicel ve nitel olarak sunulmuştur. Modelin performansı; doğruluk (Accuracy), kesinlik (Precision), duyarlılık (Recall), F1-Skor ve ROC-AUC gibi standart metrikler kullanılarak değerlendirilmiştir.

4.1. Genel Performans Metrikleri Tablosu

Modelin eğitim sürecinde Early Stopping mekanizması devreye girmiş ve validasyon kaybının en düşük olduğu noktadaki ağırlıklar kaydedilmiştir. Kaydedilen en iyi modelin, tamamen bağımsız olan Test Veri Seti (toplam 529 örnek) üzerindeki nihai performans metrikleri Tablo 2'de sunulmuştur:

Tablo 2: CNN Modelinin Nihai Test Performansı

<i>Metrik</i>	<i>Değer (0.0 - 1.0)</i>	<i>Açıklama</i>
<i>Accuracy (Doğruluk)</i>	0.8998	Test setindeki toplam doğru tahmin oranı (%89.98)
<i>Precision (Kesinlik)</i>	0.8992	Pozitif tahminlerin ne kadarının doğru olduğu
<i>Recall (Duyarlılık)</i>	0.8998	Gerçek pozitiflerin ne kadarının yakalandığı
<i>F1-Skor</i>	0.8981	Kesinlik ve Duyarlılığın harmonik ortalaması


Tablo 2 incelendiğinde, modelin tüm metriklerde yaklaşık %90 oranında bir başarı yakaladığı görülmektedir. Eğitim setinde yalnızca laboratuvar ortamı görselleri değil, ağaç üzerinde çekilmiş (yaprak, dal, gölge içeren) karmaşık görsellerin de bulunduğu göz önüne alındığında, elde edilen bu %89.98'lik doğruluk oranı, modelin özellik çıkarımı (feature extraction) ve genelleme kapasitesinin oldukça başarılı olduğunu kanıtlamaktadır.

4.2. Eğitim Sürecinin Analizi (Learning Curves)

Modelin eğitim (Train) ve doğrulama (Validation) süreçlerindeki davranışını anlamak adına Kayıp (Loss) ve Doğruluk (Accuracy) grafiklerini inceleyelim.

4.2.1. Kayıp - Dönem (Loss - Epoch) Grafiği

Aşağıdaki grafik, 50 epoch boyunca eğitim ve validasyon kayıplarının değişimini göstermektedir:




Şekil 2: Eğitim ve Validasyon Kayıp (Loss) Eğrileri

Şekil 2'de görüldüğü üzere, modelin eğitim süreci boyunca elde edilen kayıp (loss) değerleri incelendiğinde, başlangıçtan 5. döneme (epoch) kadar hem eğitim kaybının hem de doğrulama kaybının tutarlı bir şekilde düştüğü görülmektedir; bu durum modelin veri setindeki öznelikleri başarıyla öğrendiğini ve genelleme yapabildiğini gösterir. Doğrulama kaybı 5. epoch'ta minimum seviyesine ulaşarak grafikte yeşil kesik çizgiyle de belirtilen optimum noktayı, yani modelin genelleme yeteneğinin en yüksek olduğu anı işaret etmiştir. Bu kırılma noktasından sonra eğitim kaybı düşmeye devam edip 0.05 seviyelerine kadar inse de doğrulama kaybının yönünü yukarı çevirerek 0.30 bandına doğru ilerlemesi, iki eğri arasındaki makasın açılmasına sebep olmuş ve modelin eğitim verisini ezberlemeye başlayarak aşırı öğrenme (overfitting) sürecine girdiğini net bir şekilde ortaya koymuştur. Ancak sisteme entegre edilen erken durdurma (early stopping) mekanizması doğrulama kaybındaki bu bozulmayı anında tespit etmiş, belirlenen bekleme süresinin ardından eğitimi 10. epoch'ta başarıyla sonlandırarak modelin ağırlıklarını performansın zirvede olduğu 5. epoch'taki haliyle güvence altına almıştır.

4.2.2. Doğruluk - Dönem (Accuracy - Epoch) Grafiği

Aşağıdaki grafik, modelin eğitim ve doğrulama setlerindeki başarı oranlarının zamanla değişimini göstermektedir:



Şekil 3: Eğitim ve Validasyon Doğruluk (Accuracy) Eğrileri


Şekil 3'te sunulan Doğruluk - Dönem (Accuracy - Epoch) eğrisi incelendiğinde, eğitimin başlangıcından itibaren hem eğitim (mavi çizgi) hem de doğrulama (kırmızı çizgi) doğruluk değerlerinin eş zamanlı olarak hızlı bir artış gösterdiği ve modelin hedef sınıfları ayırt etme yeteneğini başarıyla kazandığı gözlemlenmektedir. 5. döneme gelindiğinde, doğrulama doğruluğu yaklaşık %90 bandına ulaşarak grafikte yeşil kesik çizgi ile işaretlenen optimum seviyeye (Best Epoch) erişmiştir. Bu noktadan sonra eğitim doğruluğu istikrarlı artışını sürdürerek %98 seviyelerine, yani neredeyse kusursuz bir ezber noktasına yaklaşırken; doğrulama doğruluğunun aynı ivmeyi koruyamayarak yatay bir seyir izlemesi ve performansın doygunluğa ulaşması, kayıp grafiğinde de tespit edilen aşırı öğrenme (overfitting) sürecini desteklemektedir. Sonuç olarak, eğitim ve doğrulama eğrileri arasındaki makasın açılmaya başladığı bu evrede devreye giren erken durdurma (early stopping) mekanizmasının, modelin genelleme yeteneğinin en yüksek olduğu 5. dönemdeki ağırlıkları kaydederek performansı güvence altına aldığı Şekil 3 üzerinden de net bir biçimde kanıtlanmıştır.

4.3. Sınıf Bazlı Performans Analizi (Sınıflandırma Detayları)

Modelin hangi sınıflarda daha başarılı olduğunu ve hangi meyveleri birbirine karıştırdığını daha iyi anlamak için Confusion Matrix ve ROC-AUC grafiklerini inceleyelim.

4.3.1. Hata Matrisi (Confusion Matrix)

Aşağıdaki hata matrisi, test setindeki 529 örneğin gerçek sınıfları ile modelin tahminlerinin detaylı bir dağılımını sunmaktadır:




Şekil 4: Test Veri Seti Hata Matrisi (Confusion Matrix)

Şekil 4'te sunulan Karmaşıklık Matrisi (Confusion Matrix), modelin test veri seti üzerindeki sınıflandırma performansını her bir sınıf özelinde detaylandırmaktadır. Matrisin ana köşegeninde yer alan koyu mavi hücreler modelin doğru tahminlerini temsil etmekte olup; 199 armut görüntüsünün 184'ünün, 187 seftali görüntüsünün 181'inin ve 143 elma görüntüsünün ise 111'inin doğru sınıflandırıldığı görülmektedir. Bu dağılım, modelin özellikle yapısal olarak daha belirgin özneliteliklere sahip olan seftali ve armut sınıflarını ayırt etmede son derece başarılı olduğunu kanıtlamaktadır. Diğer yandan, matrisin köşegen dışı değerleri incelendiğinde modelin en çok zorlandığı sınıfın elma olduğu; gerçekte elma olan 20 görüntünün armut, 12 görüntünün ise seftali olarak hatalı tahmin edildiği tespit edilmiştir. Bu durum, elmanın morfolojik yapısının, renk veya doku özelliklerinin veri setindeki diğer iki meyve türüyle görsel benzerlikler taşımasından (örneğin yuvarlak formunun seftaliyi, yeşil/sarı renk tonlarının ise armudu andırması) kaynaklanmakta olup, modelin genel başarısı yüksek olsa da spesifik olarak elma sınıfı için gelecekte veri artırma (data augmentation) gibi iyileştirme adımlarına odaklanılabileceğini açıkça ortaya koymaktadır.

4.3.2. ROC - AUC Grafiđi

Ařađıdaki Alıcı İřletim Karakteriřtiđi (Receiver Operating Characteristic - ROC) eđrisi, modelin her bir sınıfı diđerlerine karřı ayırt etme yeteneđini gorselleřtirmektedir. Eđrinin altındaki alan (AUC), modelin bařarım kalitesini gosterir (1.0 mükemmeldir):



řekil 5: Sınıf Bazlı ROC - AUC Eđrileri

řekil 5'te sunulan Çok Sınıflı ROC-AUC (Alıcı İřletim Karakteriřtiđi - Eđri Altında Kalan Alan) grafiđi, modelin farklı karar eřiklerinde sınıfları birbirinden ayırt etme kapasitesini nicel olarak deđerlendirmektedir. İdeal bir sınıflandırıcının hedeflendiđi, dođru pozitif oranının (True Positive Rate) maksimum ve yanlış pozitif oranının (False Positive Rate) minimum olduđu sol üst köřeye yakınlık durumları incelendiđinde; seftali sınıfının 0.99, armut sınıfının ise 0.98 AUC deđerine ulařarak model tarafından yüksek bir kesinlikle ayrıştırıldıđı görülmektedir. Karmařıklık matrisindeki (řekil 4) bulgularla tutarlı olarak, modelin sınıflandırma sürecinde nispeten daha fazla hata yaptıđı elma sınıfı 0.97 AUC deđerine ile eđrilerin en altında konumlanmıřtır. Buna rađmen, her üç sınıfa ait eđrilerin rastgele tahmini temsil eden diyagonal referans çizgisinin (siyah kesik çizgi) belirgin ölçüde üzerinde yer alması ve bütünüyle 1.0 referans deđerine yakın AUC skorları üretmesi, tasarlanan evriřimli sinir ađı (CNN) mimarisinin hedef sınıflar arasındaki karar sınırlarını (decision boundaries) istikrarlı ve istatistiksel açıdan anlamlı bir düzeyde modellediđini gostermektedir.

4.4. Sonuçların Genel Değerlendirilmesi

Tüm grafikler ve tablolar birlikte değerlendirildiğinde, geliştirilen CNN modelinin elma, armut ve şeftali sınıflandırmasında çok yüksek bir başarı gösterdiği kanıtlanmıştır. Model, zorlayıcı ağaç üstü görsellerine rağmen özellik çıkarımı konusunda dayanıklılığını (robustness) kanıtlamış, sadece Elma ve Armut arasında çok küçük karışıklıklar yaşamıştır. Sonuçlar, bu modelin akıllı tarım veya otomatik paketleme tesislerinde uygulanabilirliği konusunda güçlü bir potansiyele sahip olduğunu göstermektedir.

5. TARTIŞMA

Bu çalışma, derin öğrenme yöntemlerini kullanarak dijital görseller üzerinden elma, armut ve şeftali türlerini tahmin etmeyi amaçlamaktadır. Deneylerde, Evrişimli Sinir Ağları (CNN) algoritması kullanılarak sınıflandırma modelleri oluşturulmuştur. Geliştirilen modeller arasında en yüksek başarıyı; Kaggle üzerinden alınan hazır görseller ile ağaç üzerinde çekilmiş doğal görsellerin birleştirildiği hibrit veri setini kullanan ve Erken Durdurma (Early Stopping) mekanizması ile optimize edilen mimari göstermiştir. Yapılan testler sonucunda model; %89.98 oranında doğruluk, %89.92 kesinlik ve %89.81 F1-Skoru elde ederek proje için hedeflenen makul ve gerçekçi başarı kriterlerini başarıyla sağlamıştır.

Çalışmanın sonuçları, model eğitiminde hibrit veri seti kullanımının, yalnızca steril (beyaz arka planlı) veri kullanımına kıyasla daha dayanıklı bir performans sergilediğini ve genelleme yeteneğini artırdığını ortaya koymaktadır. Uygulanan veri çeşitlendirme yöntemleri sayesinde test doğruluğu yaklaşık %90 seviyesine ulaştırılmıştır. Bu sonucun temel nedenlerinden biri, veri setine yaprak, dal ve gölge gibi karmaşık arka plan unsurlarının bilinçli olarak dahil edilmesidir. Geleneksel modellerde doğruluğun düşmesine neden olabilen bu görsel karmaşa, tasarlanan mimarideki çoklu evrişim katmanları ve %50 oranındaki Dropout tekniği sayesinde başarılı bir şekilde yönetilmiş; böylece modelin nesneleri arka plandan ayırt etme gücü pekiştirilmiştir.

Çalışmanın başarılarının yanı sıra bazı zayıf yönleri de bulunmaktadır. Bunlardan ilki, sınıflandırma kapsamının şimdilik yalnızca üç meyve türüyle sınırlı kalmasıdır. Bu çalışmada oluşturulan model yalnızca belirli meyve gruplarını tahmin ettiğinden, bu üç sınıf dışındaki diğer tarımsal ürünler tahmin edilememektedir. Çalışmanın bir diğer zayıf yönü ise, hata matrisi (confusion matrix) sonuçlarında da görüldüğü üzere, morfolojik olarak birbirine çok benzeyen bazı elma ve armut türlerinin birbirine karıştırılabilmesidir. Ayrıca, binlerce görselden oluşan veri setinin işlenmesi ve modelin eğitilmesi GPU gibi yüksek donanım güçleri gerektirdiğinden, eğitimin standart cihazlarda uzun sürmesidir.

Gelecekte, veri setine farklı meyve türlerine ait yeni görseller eklenerek modelin sınıflandırma kapasitesi genişletilebilir. Böylece yalnızca elma, armut ve şeftali değil, farklı tarımsal ürünlerin de otomatik olarak sınıflandırılması mümkün hale gelebilir. Ayrıca, ilerleyen çalışmalarda yalnızca meyve türlerinin belirlenmesi değil; meyvelerin hastalıklı, çürük veya sağlıklı olup olmadığının tespit edilmesi de hedeflenmektedir. Model performansını daha da artırmak

amacıyla, ilerleyen çalışmalarda veri artırma (data augmentation) yöntemleri ve farklı derin öğrenme mimarilerinin kullanılması planlanmaktadır.

PROJE DOSYALARI

Github Reposu: https://github.com/kdemirtas34/derinogrenme_meyveler.git